DIAGNOSTIC DES

MALADIES CARDIAQUES

Pipeline Machine Learning Complet

1 000	16	9	100%
Patients	Variables	Modèles ML	Précision max

PIPELINE MÉTHODOLOGIQUE

01

Exploration des Données

EDA · 1000 patients
16 variables médicales

02

Prétraitement & Nettoyage

Encodage · Normalisation
Gestion des NaN

03

Modélisation ML

9 algorithmes testés
Validation croisée

04

Optimisation Hyperparamètres

GridSearchCV
Meilleurs paramètres

Approche rigoureuse pour la prédiction des maladies cardiaques

EXPLORATION DES DONNÉES (EDA)

Dataset Médical

1 000 patients
16 variables cliniques
Variable cible : Heart Disease

Valeurs Manquantes

340 valeurs manquantes
dans la variable
Alcohol Intake (34%)

Distribution

Analyse par genre,
âge, facteurs de risque
et corrélations

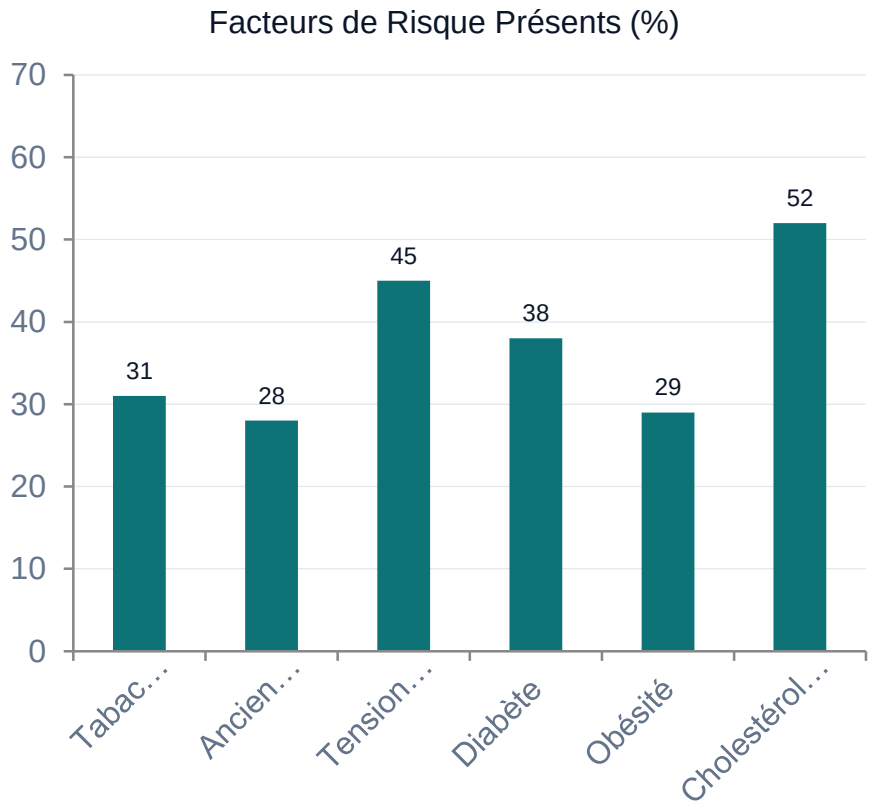

PRÉTRAITEMENT DES DONNÉES

Encodage des Variables

Variable	Encodage
Gender	Male=1, Female=0
Smoking	Never=0, Former=1, Current=2
Alcohol	NaN=0, Moderate=1, Heavy=2
Chest Pain	Typique=0 … Asymp=3
Variables binaires	Yes=1, No=0

Étapes de Transformation

1. Renommage standardisé des colonnes
2. Encodage des variables catégorielles
3. Gestion des valeurs manquantes (NaN → 0)
4. Détection & analyse des outliers
5. Normalisation MinMax & StandardScaler
6. Sauvegarde du dataset traité

Résultat : heart_disease_dataset1.csv — Dataset propre et prêt pour la modélisation

COMPARAISON DES 9 MODÈLES ML — ACCURACY

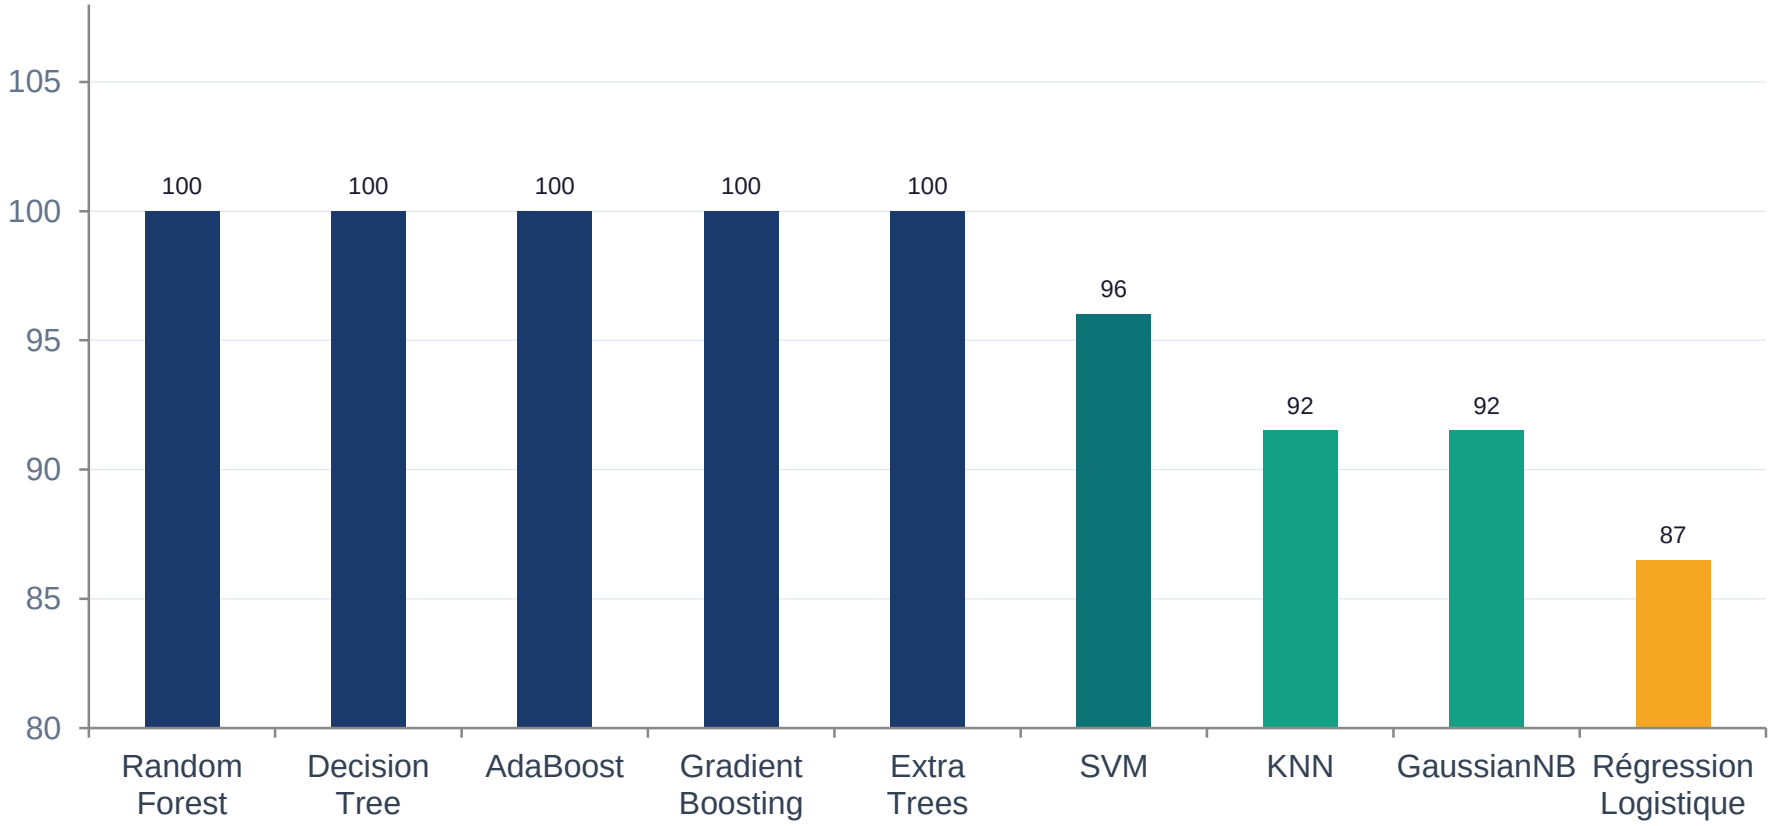

PERFORMANCES MULTICRITÈRES — AUC & MÉTRIQUES

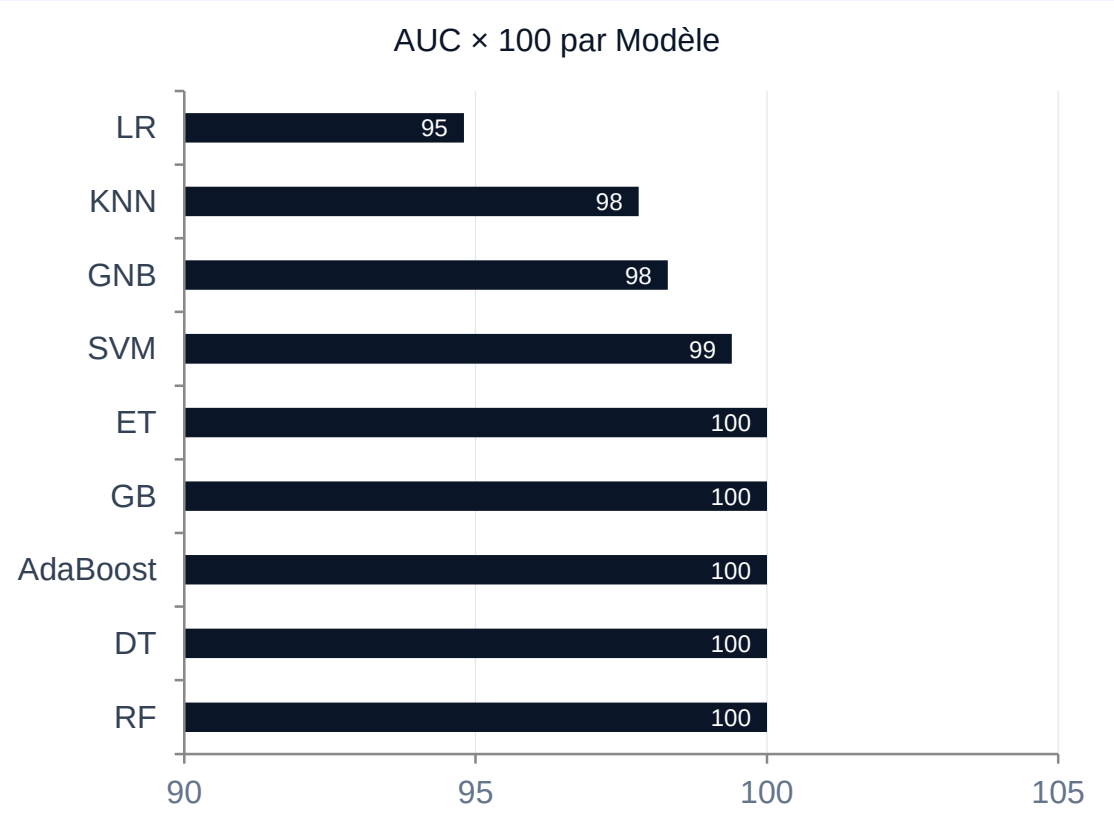

5 Modèles Parfaits

Random Forest · Decision Tree
AdaBoost · Gradient Boosting · ExtraTrees

Accuracy	100%
Precision	100%
Recall	100%
F1-Score	100%
AUC	1.000

OPTIMISATION DES HYPERPARAMÈTRES

Meilleurs Paramètres par Modèle

Modèle	Paramètres Optimaux
KNN	k=15, weights='distance'
Régression Logistique	C=4.28, solver='liblinear'
Random Forest	n_estimators=510, max_depth=5
SVM	kernel='poly', C=100
Decision Tree	max_depth=5, min_samples_split=18
AdaBoost	n_estimators=50, lr=0.1
Gradient Boosting	n_estimators=50, lr=0.01
ExtraTrees	n_estimators=700, max_depth=80

Méthodes Utilisées

GridSearchCV

Recherche exhaustive
sur grille de paramètres

RandomizedSearchCV

Recherche aléatoire
pour espaces larges

Cross-Validation

Validation croisée
5-folds stratifiée

CONCLUSION & PERSPECTIVES

5/9	1.000	96%	50+
Modèles à 100% Accuracy	AUC parfait (5 modèles)	SVM (kernel poly)	Graphiques générés

Compétences Validées

- ✓ Pipeline ML complet et professionnel
- ✓ Prévention du data leakage
- ✓ Évaluation multicritères (Acc, Prec, Rec, F1, AUC)
- ✓ Optimisation hyperparamètres (9 modèles)
- ✓ Interprétation médicale des résultats

Prochaines Étapes

- → Deep Learning & réseaux de neurones
- → Feature Engineering médical avancé
- → Stacking des meilleurs modèles
- → API REST pour intégration hospitalière
- → Dashboard de visualisation interactive