Projet Machine Learning

Prédiction des Maladies Cardiaques

Informations sur l'Étudiant

Auteur : Mohamed Hamed Ibn Hadj Mohamed

Groupe : GR2

Année : 2025 – 2026

Document de présentation du choix du dataset et du cahier des charges

1. Résumé du Cahier des Charges

Contexte Général

Ce projet a pour but de mettre en pratique les connaissances acquises en Machine Learning à travers un cas d'usage réel. L'étudiant doit démontrer sa capacité à gérer un projet de données de A à Z : de la définition du problème jusqu'à la mise en production technique (code propre, reproductible, versionné sur GitHub).

1.1. Compétences visées

- Analyse exploratoire et compréhension métier des données (EDA).
- Prétraitement et ingénierie des caractéristiques (*Feature Engineering*).
- Sélection, entraînement et optimisation de modèles ML.
- Communication technique et restitution des résultats (slides, rapport).

2. Objectifs du Projet

2.1. Problématique retenue

Question de Recherche

« Peut-on prédire de manière fiable la présence d'une maladie cardiaque chez un individu à partir de ses caractéristiques médicales et de son mode de vie ? »

2.2. Objectif technique

Il s'agit d'un problème de **classification binaire supervisée**. La variable cible `Heart Disease` prend deux valeurs :

0 — Pas de maladie cardiaque **1 — Maladie cardiaque détectée**

2.3. Justification du choix du dataset

Pourquoi ce dataset ?

- **Pertinence médicale :** Les maladies cardiaques sont la première cause de mortalité mondiale ; le problème est concret et à fort impact.
- **Richesse des features :** 15 variables couvrant démographie, biologie, mode de vie et symptômes.
- **Complexité maîtrisée :** Mélange de variables numériques et catégorielles, nécessitant un vrai travail de prétraitement.
- **Tâche bien définie :** Classification binaire claire, avec des métriques d'évaluation adaptées (AUC-ROC, F1).
- **Volume suffisant :** Respect du critère minimum de 500 lignes imposé par le cahier des charges.

3. Présentation du Dataset

3.1. Fiche d'identité

Heart Disease Prediction Dataset	
Source	Kaggle / UCI Machine Learning Repository
Domaine	Santé / Médecine
Type de tâche	Classification binaire supervisée
Nombre de lignes	1001
Nombre de colonnes	16 (15 features + 1 cible)
Variable cible	`Heart Disease` (0 = Non, 1 = Oui)
Format	CSV

3.2. Description des variables

Variable	Type	Description
Age	Numérique	Âge de l'individu (années)
Gender	Catégoriel	Genre : *Male* / *Female*
Cholesterol	Numérique	Niveau de cholestérol (mg/dL)
Blood Pressure	Numérique	Pression artérielle systolique (mmHg)
Heart Rate	Numérique	Fréquence cardiaque (bpm)
Smoking	Catégoriel	Tabagisme : *Never* / *Former* / *Current*
Alcohol Intake	Catégoriel	Alcool : *None* / *Moderate* / *Heavy*
Exercise Hours	Numérique	Heures d'exercice par semaine
Family History	Catégoriel	Antécédents familiaux : *Yes* / *No*
Diabetes	Catégoriel	Diabète : *Yes* / *No*
Obesity	Catégoriel	Obésité : *Yes* / *No*
Stress Level	Numérique	Niveau de stress (échelle 1 à 10)
Blood Sugar	Numérique	Glycémie à jeun (mg/dL)
Exercise Induced Angina	Catégoriel	Angine d'effort : *Yes* / *No*
Chest Pain Type	Catégoriel	Type de douleur thoracique (4 catégories)
Heart Disease	Cible	**Présence de maladie cardiaque : 0 = Non, 1 = Oui**

Conclusion

Ce dataset répond à l'ensemble des critères du cahier des charges : plus de 500 lignes, des variables explicatives de nature mixte (numérique et catégorielle), et une problématique de classification binaire claire dans un domaine à fort impact médical. Il constitue une base solide pour mettre en œuvre un pipeline Machine Learning complet et rigoureux.